

LLM 기반 취약 계층 초기 상담을 위한 대화 진행 및 요약 모델 연구

A Study on Dialogue Progression and Summarization Models for Initial Counseling of Vulnerable Groups Based on Large Language Models

성시윤 · 김제민 · 김준혁 · 박상은 · 정준호*

Siyoon Sung · Jemin Kim · Junhyuk Kim · Sangeun Park · Junho Jeong*

동국대학교 컴퓨터공학전공

E-mail: {bartas21, sunpal2, doodle, sss1123634}@dgu.ac.kr, yanyenli@dongguk.edu*

요약

본 논문은 복지 사각지대 취약 계층의 초기 상담 시스템에 탑재되는 LLM 기반 대화 진행 모델과 요약 모델을 제안한다. 기존의 고정된 역할 기반 시스템은 모델의 대처가 부자연스러워 상담 완료율이 20%를 채 넘기지 못하는 문제가 있었다. 제안하는 대화 진행 모델은 gpt-4o를 기반으로 하여 다양한 사용자 응답에 유연하게 대처하고, 요약 모델은 GPT-4o-mini를 기반으로 상담 이후 정보를 간결하게 요약하여 사회복지사가 효율적으로 상담 결과를 확인할 수 있도록 한다. 실험 결과, 대화 요약 모델은 96%의 높은 정확도를 기록하였으며, 대화 진행 모델은 프롬프트 엔지니어링과 미세 조정을 통해 최종적으로 62%(임시숫자)의 정확도 향상을 이루었다. 본 연구에서 제안하는 시스템은 취약 계층 초기 상담 프로세스의 개선 가능성을 보여준다.

키워드 : 도메인 챗봇, 대화 요약, 대규모 언어 모델, 자연어 처리

1. 서론

복지 사각지대에 위치한 취약 계층이 실제로 어려운 상황을 겪고 있는지 알아내어 빠른 대책 마련에 기여하는 것은 사회적으로 중요한 문제이다. 하지만, 이를 위한 기존의 역할 기반 시나리오 시스템은 기대되는 응답이 ‘예’, ‘아니오’로 제한되어 있어 정보를 구체적으로 수집하기 어려우며, 설계된 시나리오 밖의 예외 상황에 대해서는 대처할 수 없다는 문제가 있다. 실제로 보건복지부에 따르면, 이러한 단점들로 인해 취약 계층이 전화를 받는 비율이 67% 이상임에도 불구하고 상담 완료율이 20%를 채 넘기지 못하는 것으로 알려져 있다.

본 연구는, 기존의 역할 기반 시스템을 거대 언어 모델(LLM)로 대체하여 초기 상담을 진행하는 프레임워크 ‘Silver’에 탑재되는 대화 진행 모델과 대화 요약 모델을 제안한다. 이를 통해 사용자의 다양한 응답에 유연하게 대처할 수 있어 상담의 만족도와 완성률이 높아질 것으로 예상되고, 나아가 보다 정확하게 취약 계층의 정보를 파악할 수 있을 것으로 기대된다.

본 논문은 2절에서 Silver 프레임워크를 간략히 소개하고, 3절에서 Silver에 탑재된 대화 진행 및 요약 모델에 대해 설명한다. 이후 4절에서 실험 결과를, 5장에서 결론과 향후 연구에 대해 논한다.

2. Silver 프레임워크

Silver 프레임워크는 본 연구진이 개발한 취약 계층 초기 상담 자동화 시스템이다. 데이터 상의 사회적 약자들에게 통화를 걸어, 긴급히 어려운 상황이 있는지 조사하는 것이 목표이다. 간략한 구조도는 그림 1과 같다.




그림 1. Silver의 간략한 구조도
Fig. 1. Basic Diagram of Silver

그림 1처럼, Silver는 크게 STT(Speech-to-Text) 교정 및 평가 모델, 대화 모델, 요약 모델로 구성된다. 대화 진행 모델은 실제 상담자의 통화 음성이 STT 및 STT 교정 모델에 의해 최종적으로 전사된 텍스트와 대화를 진행하며, 대화 요약 모델은 상담이 종료된 이후 대화를 요약해 이후에 사회복지사가 상담 결과를 확인할 수 있게 한다. 본 논문은 LLM 기반의 대화 진행 및 요약 모델을 제안하며, Silver 프레임워크에 대한 전체적인 정보는 본 연구진의 깃허브 레포지토리에서 확인할 수 있다[1].

3. 상담 대화 진행 · 요약 모델

서론에서 언급한 바와 같이, 3절에서는 대화 진행 및 요약 모델에 대해 설명한다.

3.1 대화 진행 모델

대화 모델은 LLM을 사용하는 기본적인 취지에 걸맞게 답변의 다양성은 인정하되, 주어진 위기 유형을 누락한 것이 있는지, 사용자의 기대되지 않던 발화에 강건하게 대처할 수 있는지, 추가 질문의 개수를 충족했는지를 의미하는 ‘대화 기준’을 설계했다.

대화 모델은 ‘gpt’ 모델을 기반으로, 프롬프트 엔지니어링과 미세 조정을 통해 대화 기준을 따르도록 구현되었다. 대화 기준에 대한 설명을 프롬프트로 제공하고, 기준을 충족하는 모범적인 대화들을 학습 데이터셋으로 구성하여 모델이 패턴을 학습하게 했다. 이때, 완료된 일련의 멀티-턴(Multi-turn)대화 하나가 데이터 하나가 되며, 연구진들이 직접 취약 계층으로 위장하고 모델과 대화를 하여 데이터를 구축하였다. 총 217개의 데이터를 생성하였는데, 데이터는 ‘대화 기준’에 어긋나는 내용이 있다면 기준을 만족하도록 수정하였다. 이를 통해 모델이 틀린 내용을 바로잡아주고 유사한 오류 및 예외 상황에 대해 대처하는 패턴을 학습하도록 구현하였다.

3.2 대화 요약 모델

요약 모델의 핵심 기능은 상담 대화에서 중요한 내용을 선별하고 이를 요약하는 것이다. 상담자가 직면한 ‘위기상황’(안전, 건강, 일상생활 유지, 가족관계, 사회적 관계, 경제, 교육, 고용, 생활환경, 법률 및 권익보장)을 10가지로 분류해 핵심 정보를 요약함으로 상담사가 내담자의 문제를 파악할 수 있도록 해야 한다.

요약 모델은 GPT-4o-mini 기반으로 설계되었으며, 대화에서 불필요한 내용을 배제하고 중요한 정보만을 요약하도록 훈련하고, 상담 내용과 일치하는 일관된 요약문을 작성하는 데 중점을 두었다.

요약 모델의 성능 개선은 세 가지 주요 영역에서 이루어졌다. 첫째, 프롬프트 작성의 고도화를 통해 모델이 대화에서 중요한 정보를 효율적으로 추출하고 요약할 수 있도록 했다. 둘째, G-Eval 기법[2]을 활용한 요약 평가 모델을 도입해 자동화된 평가와 피드백을 통해 요약 품질을 향상시켰다. 셋째, 요약 평가 모델 활용으로 요약 모델의 신뢰성과 출력 일관성이 더욱 강화되었다.

프롬프트 작성은 요약 모델 성능 향상의 핵심 요소로, 대화에서 불필요한 정보를 배제하고 중요한 내용을 정확하게 요약할 수 있도록 세부적인 규칙을 도입했다. 10가지 ‘위기상황’에 따른 상담을 기반으로 정보 선별을 지시하며, 형식적인 인사말 등 불필요한 문구는 제외하도록 설정되었다. 또한, “?” 문자를 활용해 상담자의 답변에 집중하도록 프롬프트를 최적화하여, 모델이 핵심 정보를 놓치지 않고 요약문을 생성할 수 있게 했다.

요약 모델의 품질 평가 기준으로는 G-Eval 연구에 나타난 일관성, 유창성, 일치성 3가지 평가 기준과 이 연구의 요약문에 대한 특수성을 고려한 평가 기준인 선별성이 추가로 사용되었다. 선별성은 요약문이 상담자의 상황을 명확하게 반영하고 불필요한 정보가 포함되지 않았는지를 측정한다. 평가기준마다 1~10점 사이의 점수를 부여하고 그 근거를 설명하는 방식으로 자동 피드백을 제공해 시간과 자원을 절약하면서도 요약 모델의 성능을 지속적으로 개선할 수 있었다.

4. 실험 결과

여기 3절에서는, 2절에서 제안된 시스템의 실험 결과에 대해 소개한다. 3.1에서 대화 진행 모델의 실험 결과를, 3.2에서 대화 요약 모델의 실험 결과를 설명한다.

4.1 대화 진행 모델

대화 진행 모델을 측정할 때는 정확도(Accuracy)를 바탕으로 측정한다. 모델과 상담을 한 번 완료했을 때, 해당 상담이 ‘대화 기준’을 모두 충족하는지, 그렇지 않은지를 계산하는 것이다. 실험은 100회 반복해서 진행하며, 일반 gpt 모델과 Silver에 탑재된 모델의 정확도를 비교한다. 표 1은 실험 결과를 나타낸다.

	Silver 대화 모델	기본 모델
정확도		

표 1. Silver 대화 모델과 기본 모델 정확도 비교
Table 1. Comparison of Accuracy Between the Silver’s Conversation Model and the Base Model

4.2 대화 요약 모델

50개의 상담 데이터를 기반으로, G-Eval을 통해 평균 8점 이상의 점수를 받은 요약문을 데이터로 활용해 모델을 학습하여 성능을 개선했다.

실험 결과인 표 2를 근거로 학습 데이터가 증가할 경우 모델의 지속적인 성능 향상이 예상되며, 자동화된 평가 시스템을 통해 인간의 개입 없이도 요약문 품질을 개선할 수 있는 체계를 구성했다.

	학습 전	데이터 18개 학습 후	데이터 44개 학습 후
정확도	36%	88%	96%

표 2. 요약 모델 정확도 비교
Table 2. Comparison of Accuracy Between the Base Model and Finetuned Model

5. 결론 및 향후 연구

4절의 실험 결과를 바탕으로, 대화 진행 모델은 프롬프트 엔지니어링과 미세 조정을 통해 정확도가 향상되었으며, 대화 요약 모델 역시 96%의 높은 정확도를 달성했음을 확인할 수 있었다. 이는 본 연구에서 제안하는 취약 계층 초기 상담 프레임워크에 LLM을 접목시킨다는 아이디어가 유효함을 입증한다. 나아가, 본 연구를 통해 취약 계층에 대한 초기 상담을 기존의 역할 기반 시스템에 비해 유연하게 진행하게 되어 만족도와 정확도가 높은 상담에 기여할 것으로 기대된다.

하지만, 본 연구의 한계점 또한 존재한다. 대화 진행 모델과 요약 모델 모두 예외 상황에 대한 강건성을 위해서는 많은 양질의 데이터를 필요로 하지만, 이를 구축하는 것은 비용이 높은 과제이기 때문이다.

참 고 문 헌

- [1]<https://github.com/CSID-DGU/2024-1-CECD1-PM4-7>
- [2] LIU, Yang, et al. G-eval: Nlg evaluation using gpt-4 with better human alignment. arXiv preprint arXiv:2303.16634, 2023.